

# Algorytm genetyczny

Kacper Grzesik 52684, Dominik Górski 52679

## 1. main.py

Główny plik zawierający algorytm genetyczny.

### a) Podanie danych wejściowych

Nazwa zmiennej	Znaczenie
generate_population_size	populacja na generację
generation_limit	maksymalna ilość generacji
mutation_probability	szansa na mutację
file	plik do analizy
file_optimum	plik z optimum
verbose	czy printować output

```
# DATA
generate_population_size = 200
generation_limit = 100
mutation_probability = 0.2
verbose = False # should print the output

file = open("large_scale/knapPI_1_100_1000_1", "r") # file to analize
file_optimum = open("large_scale-optimum/knapPI_1_100_1000_1", "r") # file with optimum
```

### b) Ustalenie funkcji selekcji oraz krzyżowania w ewolucji

Odbywa się to przez komentowanie niepotrzebnych funkcji. Zostało to rozszerzone w podpunktach związanych z rysowaniem wykresów.

```
# evolution
def run_evolution(
    populate_func,
    fitness_func,
    fitness_limit: int, # if fitness of the best solution exceeds the limit, it's done
    selection_func = roulette_wheel_selection_pair,
    # selection_func = ranking_selection_pair,
    # selection_func = tournament_selection_pair,
    # crossover_func = single_point_crossover,
    crossover_func = two_point_crossover,
    mutation_func = mutation,
    generation_limit = generation_limit
):
    """Run evolution algorithm for a given number of generations.
    The algorithm starts with an initial population and iteratively
    selects parents, performs crossover and mutation to produce
    offspring, and updates the population until either the fitness
    limit is reached or the maximum number of generations is reached.
    The final population is returned along with the best solution found
    and its fitness value.
    """
    population = [PopulationItem(item=item, fitness=fitness_func(item)) for item in
                  generate_population(populate_func, population_size)]
    for _ in range(generation_limit):
        population = selection_func(population)
        population = crossover_func(population)
        population = mutation_func(population)
        population = sorted(population, key=lambda item: item.fitness, reverse=True)
        if population[0].fitness >= fitness_limit:
            break
```

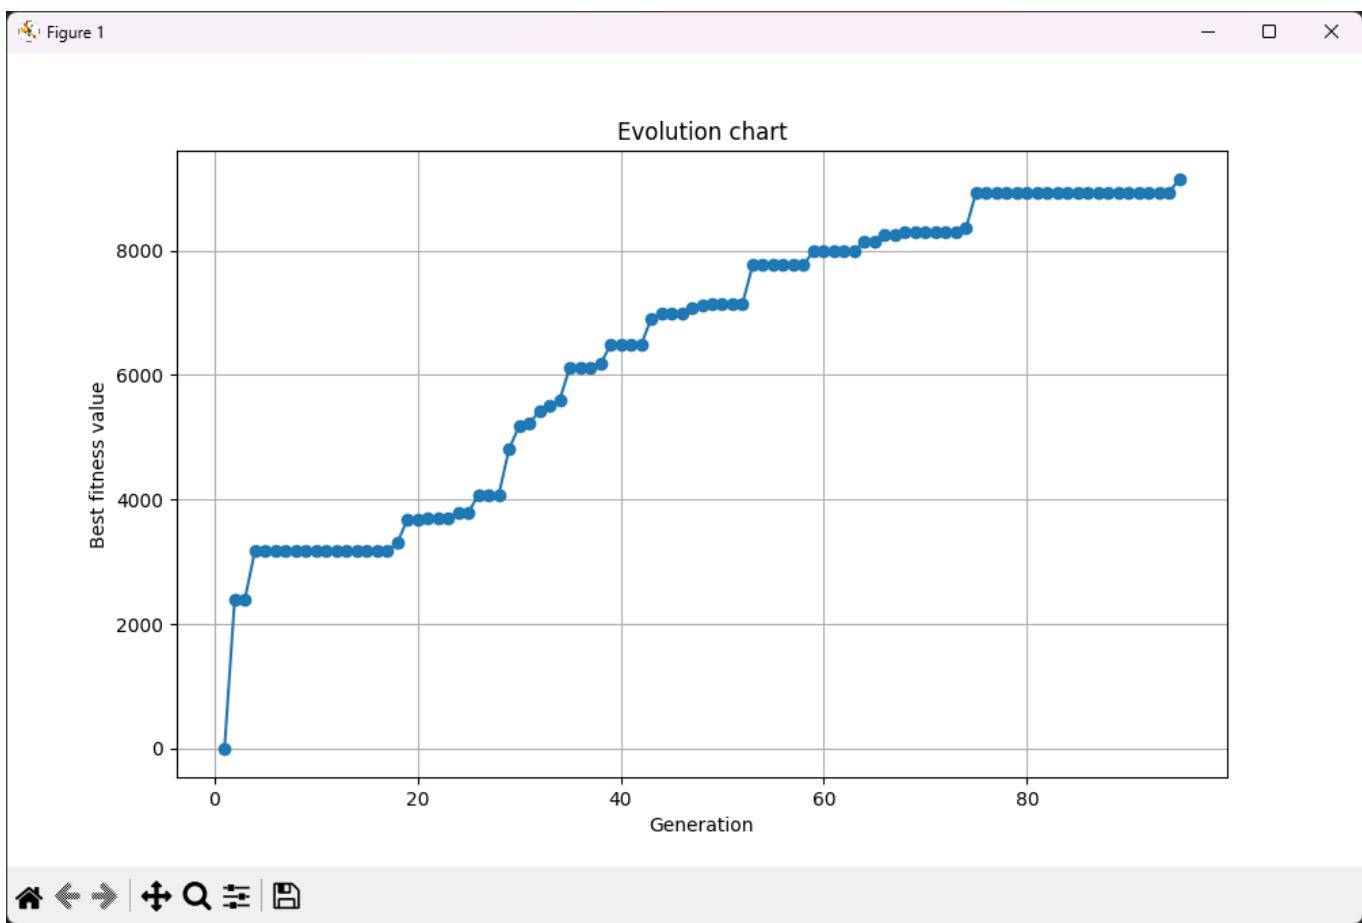
### c) Uzyskanie wyników (jeśli verbose = True)

```
Population size: 200
Mutation probability: 0.2
Number of generations: 100
Time: 6.397189499999513s
Best solution: [791, 874, 908, 569, 931, 726, 724, 641, 800, 992]
Item count: 10
Best solution value sum: 7956
Optimum: 9147
```

## 2. draw\_chart.py

Generowanie wykresu na podstawie programu main.py.

Program musiał zostać zmodyfikowany tak, aby śledzić jednostkę o najwyższy fitnessie dla każdej ewolucji.



### 3. experiments.py

Program rysuje wykresy dla różnych parametrów funkcji algorytmu genetycznego za pomocą biblioteki matplotlib.pyplot

#### a) Dane początkowe

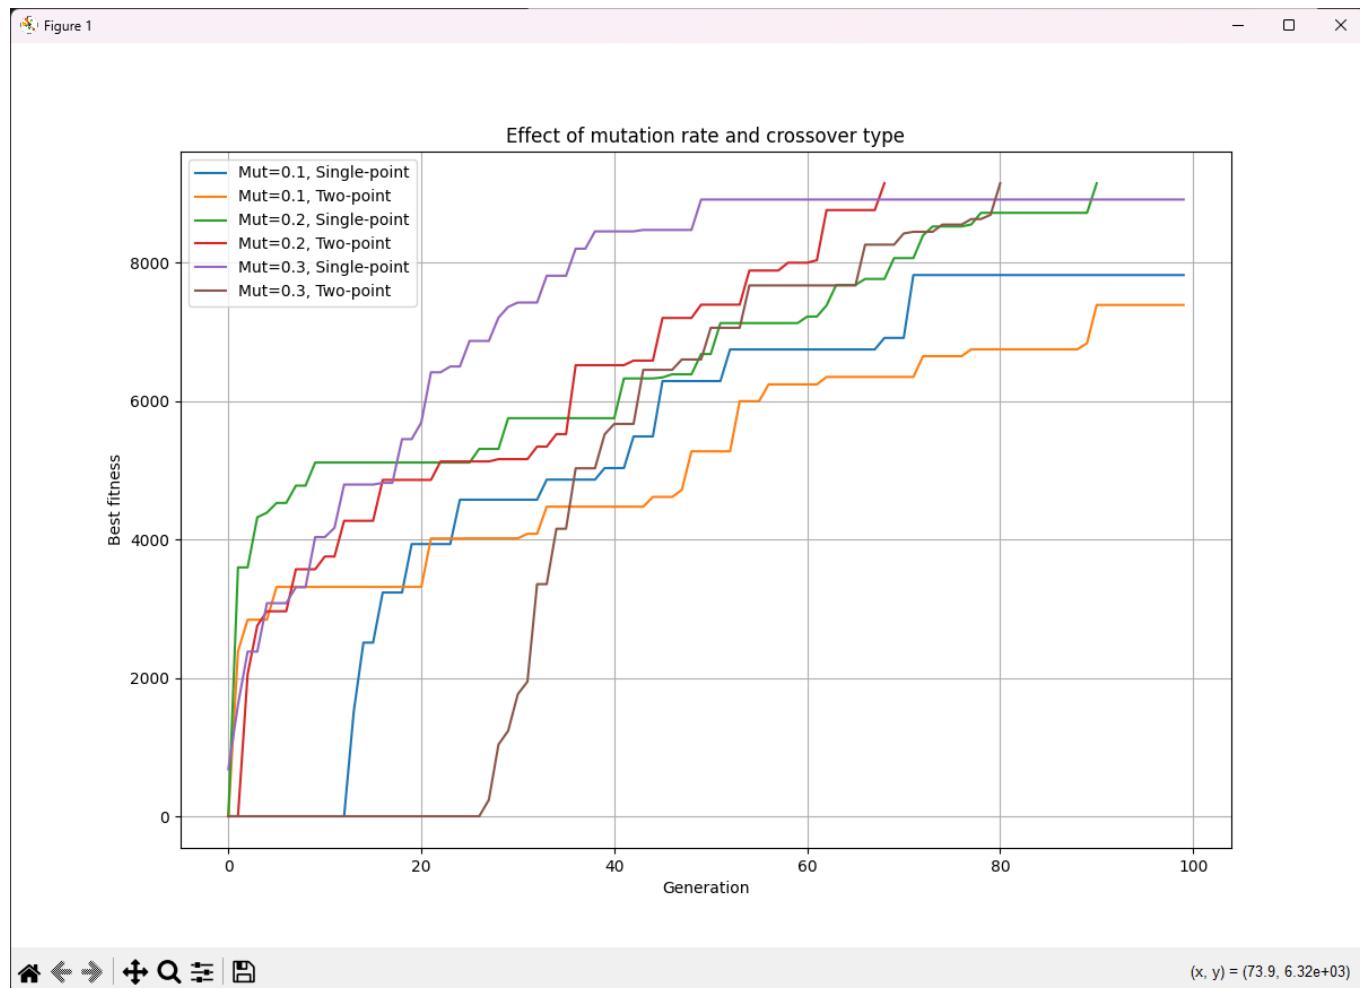
```
# experiment parameters
crossover_methods = {
    "Single-point": single_point_crossover,
    "Two-point": two_point_crossover
}

mutation_rates = [0.1, 0.2, 0.3]

selection_methods = {
    "Roulette": roulette_wheel_selection_pair,
    "Ranking": ranking_selection_pair,
    "Tournament": tournament_selection_pair
}
```

#### b) Dane wyjściowe (wykresy)

## Wykresy dla różnych współczynników mutacji i krzyżowania:



## Wykresy porównujące selekcję rankingową, ruletkową oraz turniejową, krzyżowanie jedno i dwupunktowe:

